Concurrencia

Paradigmas de la programaación FaMAF-UNC 2015 basado en filminas de Tom Mitchell capítulo 15

concurrencia

dos o más secuencias de eventos ocurren en paralelo

- Multiprogramación
 - una computadora ejecuta varios programas a la vez
 - cada programa funciona secuencialmente
 - las acciones de un programa pueden suceder entre dos pasos de otro

- Multiprocesos
 - dos o más procesadores conectados
 - los programas de un procesador se comunican con los del otro
 - las acciones pueden suceder en simultáneo

proceso: programa secuencial ejecutándose en un procesador

la promesa de la concurrencia

- velocidad
 - si una tarea toma t tiempo en un procesador, no debería tomar t/n tiempo en n procesadores?
- disponibilidad
 - si un proceso está ocupado, otro podrá ayudar
- distribución
 - los procesadores de diferentes lugares pueden colaborar en solucionar un problema o trabajar juntos
- si los humanos lo hacen, las computadoras también
 - visión, cognición, parecen actividades fuertemente paralelas

retos

- los programas concurrentes son más difíciles de sacar bien
- algunos problemas son inherentemente secuenciales, y requieren mucha coordinación y comunicación entre sub-problemas si los paralelizamos
- problemas a resolver
 - comunicación cómo recibir o enviar información
 - sincronización cómo esperar a otro proceso
 - atomicidad garantizar que no se va a parar en la mitad y dejar todo embrollado

y en paradigmas...

 cómo hacen los lenguajes de programación para facilitar la programación concurrente y la corrección de los programas concurrentes?

qué esperamos de un lenguaje concurrente: construcciones

- hilos (threads) como valores de expresiones
 - se pueden pasar hilos a funciones, crear hilos como resultado de una llamada a función
- abstracciones de comunicación
 - comunicación síncrona
 - canales con búfer asíncronos que preservan el orden de los mensajes
- control de concurrencia
 - exclusión mútua
 - alguna forma de cerrojo (*lock*)
 - la atomicidad no es tan común en los lenguajes

problema básico: condiciones de carrera

```
procedure anotar(persona)
  begin
  numero := numero + 1;
  list[numero] := persona;
end;
```

problema con la ejecución en paralelo

```
anotar(fred) | anotar(bill); | bill | fred
```

resolver conflictos entre procesos

sección crítica

- dos procesos que acceden a un recurso compartido
- comportamiento inconsistente si se intercalan dos acciones

permitimos un solo proceso en la sección crítica

deadlock

- un proceso puede estar reteniendo locks mientras está esperando a otros
- el deadlock ocurre cuando ningún proceso puede continuar

locks y espera

```
<initialze control de concurrencia>
Thread 1:
  <wait>
  anotar(fred); // sección crítica
  <signal>
Thread 2:
  <wait>
    anotar(bill); // sección crítica
  <signal>
```

se necesitan operaciones atómicas para implementar wait

primitivas de exclusión mútua

test-and-set atómico

- una instrucción lee y escribe de forma atómica
- es una instrucción de hardware común
- se combina con el bucle ocupado-en espera para implementar mutex

semáforo

- se evita el bucle ocupado-en espera
- se mantiene una cola de procesos en espera
- el scheduler tiene acceso al semáforo, el proceso duerme
- se inhabilitan interrupciones durante las operaciones de semáforo

estado de la cuestión

- la programación concurrente es difícil
 - difícil darse cuenta de cuándo se van a dar condiciones de carrera o deadlocks
- los lenguajes deberían ayudar con patrones, abstracciones, paradigmas útiles
- se necesitan otras herramientas
 - el testing es difícil por la explosión combinatoria
 - hay detectores de condiciones de carrera
 - estáticos: conservadores, quizás demasiado restrictivos
 - en ejecución: más prácticos por el momento

Cobegin/coend

primitiva de concurrencia limitada

```
x := 0;
cobegin
begin x := 1; x := x+1 end;
begin x := 2; x := x+1 end;
coend;
print(x);
x := 1
x := x+1
print(x)
```

la atomicidad está al nivel de la sentencia de asignación

propiedades de cobegin/coend

ventajas

- crea procesos concurrentes
- comunicación mediante variables compartidas

limitaciones

- sin exclusión mútua
- sin atomicidad
- el número de procesos está fijo por la estructura del programa
- no se pueden abortar procesos, todos se tienen que completar para que el padre pueda seguir

Concurrent Pascal, P. Brinch Hansen, Caltech, 1970's

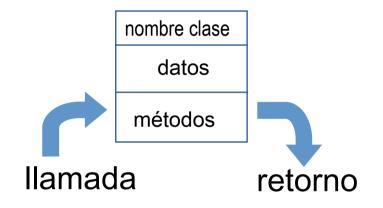
Actores

[Hewitt, Agha, Tokoro, Yonezawa, ...]

- cada actor (objeto) tiene un script
- en respuesta a un input, el actor atómicamente
 - crea nuevos actores
 - inicia una comunicación
 - cambia su estado interno
- la comunicación es
 - en búfer, sin pérdida
 - no se garantiza el orden de llegada
 - preservar el orden es más difícil de implementar
 - el programador puede reconstruir el orden si es necesario
 - es ineficiente tener comunicación ordenada si no es necesario

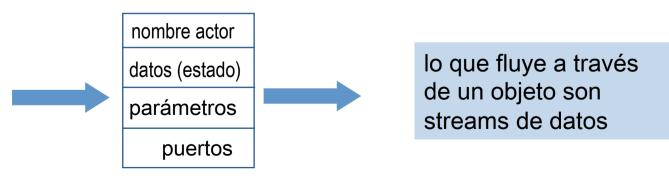
programas orientados a actores

orientación a objetos:



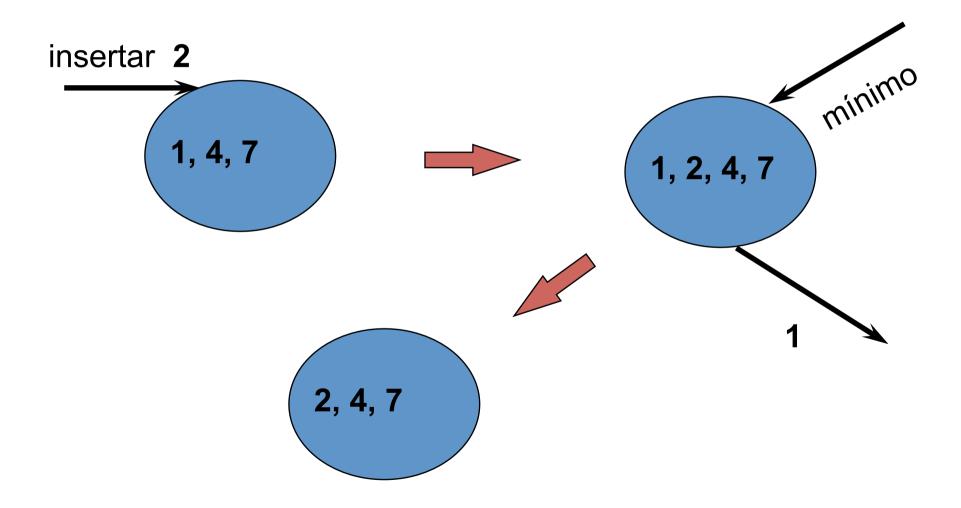
lo que fluye a través de un objeto es control secuencial

orientación a actores:



input data output data

ejemplo



pila implementada con actores

parámetros

```
nodo_pila con acquaintances contenido y link
  if operación requerida es pop y contenido != nil then
    convertirse en forwarder hacia link
    enviar contenido al cliente
  if operación requerida es push(nuevo_contenido) then
    let P=new nodo_pila con acquaintances actuales (clon)
    convertirse en nodo_pila con acquaintances
    nuevo_contenido y P
```

difícil de leer pero tiene la semántica denotacional de una pila, sólo que *forwarder* es inusual....

Forwarder

pila antes de pop



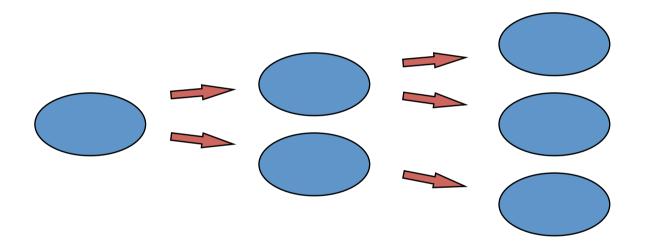
pila después de pop



el nodo "desaparece" convirtiéndose en un nodo *forwarder*. El sistema maneja los nodos forwardeados de forma que se convierten invisibles al programa.

concurrencia

muchos actores pueden operar concurrentemente



- no es necesario controlar explícitamente la concurrencia
- los mensajes enviados por un actor pueden ser recibidos y procesados por otros secuencialmente o concurrentemente

Pros y contras del modelo de actores

- lenguaje de programación de alto nivel
 - comunicación por mensajes
 - exclusión mútua: si se envían dos mensajes, los actores reaccionan atómicamente al primero que reciben antes de ver el segundo
 - la concurrencia es implícita
- quizás demasiado abstracto para algunas situaciones?
 - cómo hacer fork de varios procesos para hacer cómputo especulativo, y terminarlos a todos cuando uno encuentra la solución?
 - el coordinador de todo el resto de actores se convierte en cuello de botella

ML concurrente [Reppy, Gansner, ...]

- threads
 - son una entidad (un tipo)
- comunicación
 - canales sincrónicos
- sincronización
 - canales
 - eventos
- atomicidad
 - no hay soporte específico en el lenguaje

Brinch-Hansen, Dahl, Dijkstra, Hoare

concepto previo a Java: monitor

- acceso sincronizado a datos privados
- encapsula:
 - datos privados
 - conjunto de procedimientos (métodos)
 - política de sincronización
 - máximo un objeto puede ejecutar un procedimiento del monitor a la vez, se dice que el proceso está en el monitor
 - si un proceso está en el monitor, los otros procesos que llaman a un procedimiento del monitor serán demorados
- en terminología moderna: objeto sincronizado

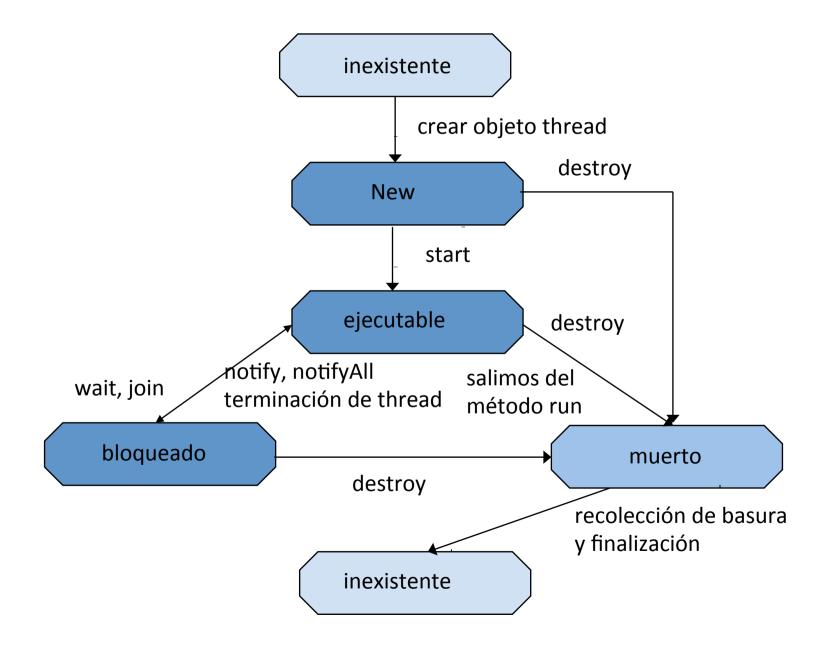
concurrencia en Java

- threads
 - crean un proceso creando un objeto thread o implementando una interfaz
- comunicación
 - variables compartidas
 - llamadas a métodos
- exclusión mútua y sincronización
 - cada objeto tiene un lock (heredado de la clase Object)
 - métodos y bloques sincronizados
 - operaciones de sincronización (heredado de la clase Object)
 - wait: pausar el thread actual hasta que le hacen notify
 - notify: despertar threads que están esperando

threads de Java

- un thread es un conjunto de instrucciones que se ejecutan secuencialmente
- en Java, son objetos
 - de la clase Thread
 - métodos que se heredan de Thread:
 - start : reproduce (*spawn*) un nuevo thread, hace que la máquina virtual llame al método run
 - suspend : congela la ejecución
 - interrupt : congela la ejecución y lanza una excepción
 - stop: fuerza el thread a detenerse

estados de un thread en Java



un problema con la especificación de Java

Java perite acceso a objetos parciales

```
class Broken {
  private long x;
  Broken() {
    new Thread() {
      public void run() { x = -1; }
    }.start();
    x = 0;
}
```

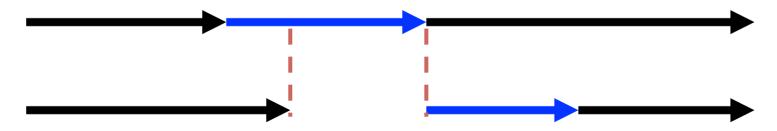
Thread created within constructor can access the object not fully constructed

interacción entre threads

- variables compartidas
 - dos threads pueden asignar/leer a la misma variable
 - responsabilidad del programador: hay que evitar condiciones de carrera explícitamente
- llamadas a métodos
 - dos threads pueden llamar a métodos del mismo objeto, y ahí se ponen en funcionamiento los locks propios del objeto
 - cada objeto tiene un lock interno, heredado de Object
 - las primitivas de sincronización se basan en ese lock

sincronización

- provee exclusión mútua
 - dos threads pueden tener acceso al mismo objeto
 - si un thread llama un método sincronizado, el objeto se cierra (lock)
 - si otro thread llama a un método sincronizado del mismo objeto, el thread se bloquea hasta que el objeto se abre (unlock)



métodos sincronizados

- se marcan con una palabra clave
 - public synchronized void commitTransaction(...) {...}
- máximo un método sincronizado puede estar activo
- los métodos no sincronizados se pueden llamar: el programador tiene que ir con cuidado!
- no es parte de la signatura del método
 - un método sincronizado es equivalente a uno no sincronizado con el mismo cuerpo
 - una subclase puede sustituir un método sincronizado con uno no sincronizado

ejemplo

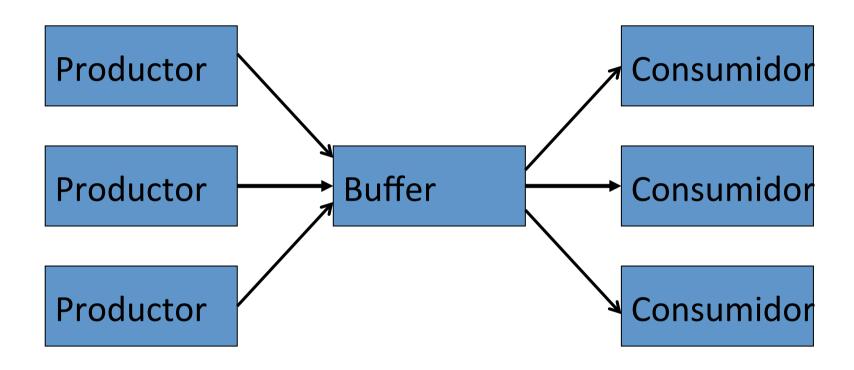
```
class LinkedCell {      // una celda con un valor y un link a la siguiente
  protected double value;
  protected final LinkedCell next;
  public LinkedCell (double v, LinkedCell t) {
      value = v; next = t;
  public synchronized double getValue() {
      return value;
  public synchronized void setValue(double v) {
      value = v; // la asignación no es atómica
  public LinkedCell next() { // no requiere sincronización
      return next;
```

Join, otra forma de sincronización

espera a que termine un thread

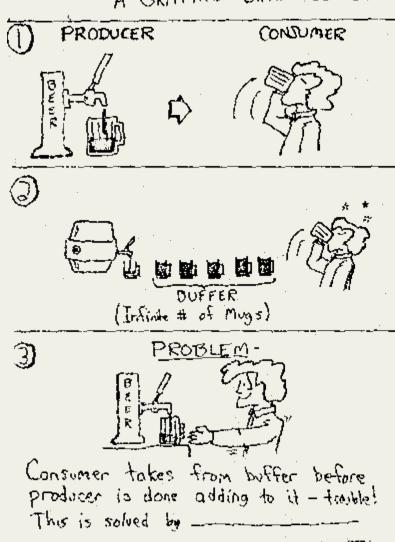
```
class Future extends Thread {
   private int result;
   public void run() { result = f(...); }
   public int getResult() { return result;}
}
...
Future t = new future;
t.start() // empieza un nuevo thread
...
t.join(); x = t.getResult(); // espera y obtiene
   resultado
```

productor-consumidor?

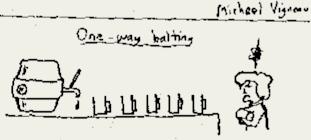


- la llamada a métodos es síncrona
- cómo se hace en Java?

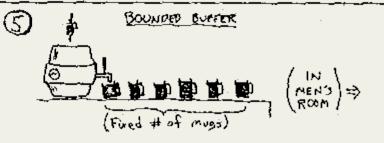
A GRAPHIC EXAMPLE OF THE PROPUCET/CONSUMER PROBLEM



(Full in the blank)



The consumer must wait for producer to produce before it can consume...



If the consumer is busy (can't consumely, the producer must wait, if the buffer is full, for the consumer to start consuming again. The processes are now (fill in)

solución al productor-consumidor

- no se puede resolver solamente con locks: se usan los métodos wait y notify
- el consumidor espera hasta que hay algo en el buffer
 - mientras espera, tiene que dormir, con el método wait
 - se requiere un bucle de rechequeo de la condición que lo tiene durmiendo
- el productor informa a los consumidores que esperan cuando hay algo en el buffer
 - tiene que despertar por lo menos a un consumidor, con el método notify

Stack<T>: métodos produce, consume

```
public synchronized void produce (T object) {
  stack.add(object); notify();
public synchronized T consume () {
 while (stack.isEmpty()) {
   try {
      wait();
                                           este loop?
   } catch (InterruptedException e) {
  Int lastElement = stack.size() - 1;
  T object = stack.get(lastElement);
  stack.remove(lastElement);
  return object; }
```

Concurrent garbage collector

- How much concurrencia?
 - Need to stop thread while mark and sweep
 - Other GC: may not need to stop all programa threads
- Problem
 - programa thread may change objects during collection
- Solution
 - Prevento read/write to memory area
 - Details are subtle; generational, copying GC
 - Modern GC distinguishes short-lived from long-lived objects
 - Copying allows read to old area if writes are blocked ...
 - Relatively efficient methods for read barrier, write barrier

limitaciones de las primitivas de Java 1.4

- no se puede volver del intento de adquirir un lock
 - no se puede desistir después de haber esperado por un cierto tiempo
 - no se puede cancelar un intento de adquirir un lock después de una interrupción
- no se puede alterar la semántica de un lock
 - protección de lectura vs. escritura, fairness, ...
- no hay control de acceso a sincronización
 - cualquier método puede hacer synchronized(obj) para cualquier objeto
- la sincronización se hace con métodos y bloques
 - no se puede adquirir un lock en un método y soltarlo en otro